Progetto del corso Sistemi Distribuiti: Paradigmi e Modelli, 2012/2013

Jacopo Notarstefano
jacopo.notarstefano [at] gmail.com

1 Introduzione

Scopo di questo progetto è dare un'implementazione sequenziale e una parallela di una soluzione al problema dell'Histogram Thresholding, per poi confrontarne le performance sia fra esse sia con i modelli teorici.

Entrambe le implementazioni sono realizzate in C++; in particolare quella parallela è data in termini di parallel skeleton, più nello specifico quelli forniti dal framework SkeTo.

SkeTo è uno skeleton framework in cui dichiarazione e istanziazione degli skeleton avvengono allo stesso tempo. I metodi offerti dalle classi astratte del framework, implementate in termini di template, sono quelli tipici della programmazione funzionale, come `map`, `reduce` e `scan`. Queste caratteristiche rendono molto compatto il codice: in effetti l'intero codice non funzionale parallelo di `src/parallel.cpp` ammonta a 63 righe commenti inclusi, di cui appena 3 chiamate di libreria.

Il codice non funzionale sequenziale di `src/sequential.cpp` è un ordinario programma C++. La struttura delle due implementazioni è molto simile: questo perché il business code dell'applicazione è stato incapsulato nella classe `Job`, la cui interfaccia è definita in `src/job.h` e la cui implementazione in `src/job.cpp`.

Per prima cosa presentiamo il problema dell'Histogram Thresholding e descriviamo l'algoritmo risolutivo implementato. In seguito descriviamo in maggiore dettaglio le scelte implementative adottate durante lo sviluppo. Parte centrale del lavoro è il confronto delle performance con le previsioni teoriche, seguito da una dimostrazione dei risultati ottenuti dal programma. Concludiamo con un manuale d'uso che contiene le rule definite nel `Makefile` e altri script disponibili.

2 Il problema dell'Histogram Thresholding

Siano `I` un'immagine e `p` una percentuale. Supponiamo di avere accesso ai singoli pixel dell'immagine, e denotiamo con `I[i][j]` il pixel alla riga `i` e colonna `j`. Il problema dell'Histogram Thresholding consiste nel restituire un'immagine in bianco e nero `BW` tale che

il pixel `BW[i][j]` sia bianco se il pixel `I[i][j]` è più luminoso di `p`% pixel dell'immagine originaria, nero altrimenti.[1]

L'algoritmo di risoluzione implementato visita ogni pixel, ne calcola la luminosità e la scrive in un vettore. Successivamente lo ordina e ricava la luminosità soglia per la percentuale `p`. Infine visita nuovamente ogni pixel dell'immagine originaria e, confrontando con il valore soglia precedentemente ottenuto, assegna al corrispondente pixel dell'immagine risultante il colore bianco o nero. Più precisamente abbiamo il seguente:

Algoritmo 1 NAÏVE HISTOGRAM THRESHOLDING

Input: `p` intero, $0 \leq$ `p` < 100, `I` immagine di larghezza `imageWidth` e altezza `imageHeight`

```
1: luminosities = []
2: for i ≤ imageWidth do
3:   for j ≤ imageHeight do
4:     luminosities.push(I[i][j].luminosity())
5: luminosities.sort()
6: threshold ← luminosities[luminosities.length() * p / 100]
7: for i ≤ imageWidth do
8:   for j ≤ imageHeight do
9:     if I[i][j].luminosity() > threshold then
10:      BW[i][j] ← white
11:    else
12:      BW[i][j] ← black
13: return BW
```

3 Descrizione delle implementazioni

Abbiamo posto particolare enfasi nella divisione fra codice funzionale e non funzionale; in particolare il business code dell'applicazione è interamente astratto nella classe `Job`, di cui diamo di seguito l'interfaccia:

```
/*
 * File: job.h
 * -----------
 * This interface exports a class for representing jobs
 * computing histogram thresholding on a single image.
 */

#ifndef _job_h
#define _job_h
```

[1] Osserviamo che in letteratura esistono più definizioni di luminosità di un pixel; le soluzioni proposte usano la coordinata `L` nello spazio colori `HSL`.

```
#include "Magick++.h"

class Job {

public:

/*
 * Constructor: Job
 * Usage: Job j;
 *        Job j(percentage);
 * -------------------------
 * Creates a Job object. The default constructor creates a job with
 * percentage set to 50%. The percentage can be passed explicitly
 * to the constructor.
 */

        Job();
        Job(int);

/*
 * Method: execute()
 * Usage: j.execute();
 * -------------------
 * Performs histogram thresholding. Returns itself so that this
 * method can be chained or used in a sketo::map.
 */

        Job execute();

/*
 * Method: writeResult();
 * Usage: j.writeResult();
 * -----------------------
 * Writes the result to disk. Returns itself so that this method
 * can be chained or used in a sketo::map.
 */

        Job writeResult();

private:
```

```
        Magick::Image originalImage;
        Magick::Image processedImage;
        int percentage;

};

#endif
```

Osserviamo che i metodi `execute` e `writeResult` hanno come tipo di ritorno `Job`; in effetti questi metodi ritornano l'oggetto stesso. Ciò consente di usarli in `sequential.cpp` come se avessero tipo di ritorno `void` (cioè ignorandone il valore di ritorno), e in `parallel.cpp`, come argomento di `generate` e `map`, dopo averli astratti in opportuni function object come nel seguente esempio:

```
struct generate_t : public sketo::functions::base<Job(size_t)> {
        Job operator()(size_t) const {
                int percentage = rand() % 100;
                return Job(percentage);
        }
} generate;
```

Come già ricordato l'implementazione parallela si avvale di SkeTo, in particolare la versione `1.1`. Esiste una versione più aggiornata, la `1.50pre`, scartata perché ad oggi priva di documentazione. Internamente SkeTo si avvale di un'implementazione disponibile di MPI; quella utilizzata da questo progetto è la distribuzione MPICH versione `3.0.4`. Infine la lettura e scrittura delle immagini sono interamente delegate alla libreria ImageMagick tramite Magick++, la sua API per C++, versione `6.8.6-1`.

4 Valutazione delle performance

I seguenti test sono stati svolti su `andromeda.di.unipi.it`, macchina dotata di 16 core. In particolare sono stati utilizzati per la raccolta dati gli script `test_sequential` e `test_parallel` descritti in appendice.

Siano T_{seq} e $T_{\text{par}}(n)$ rispettivamente il service time dell'applicazione sequenziale e di quella parallela con grado di parallelismo n. L'esecuzione degli script `awk -f sequential.awk sequential.dat` e `awk -f parallel.awk parallel.dat` porta a stimare $T_{\text{seq}} \approx 0.86$ e $T_{\text{par}}(n)$ come dalla seguente tabella:

n	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
$T_{\text{par}}(n)$	.89	.46	.38	.28	.18	.19	.19	.20	.19	.13	.14	.17	.16	.17	.18	.18

L'esecuzione dello script `awk -f speedup.awk parallel.dat` permette di stimare lo speedup $s(n)$ come segue:

n	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
$s(n)$	0.96	1.85	2.29	3.03	4.67	4.49	4.53	4.39	4.50	6.72	6.03	5.17	5.49	5.18	4.72	4.84

Dallo script `awk -f scalability.awk parallel.dat` ricaviamo le seguenti stime per la scalabilità scalab(n):

n	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
scalab(n)	1.00	1.92	2.37	3.15	4.85	4.66	4.71	4.56	4.68	6.98	6.26	5.37	5.70	5.38	4.91	5.02

Inoltre dallo script `awk -f efficiency.awk parallel.dat` possiamo stimare l'efficienza $\epsilon(n)$ come in tabella:

n	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
$\epsilon(n)$	.96	.93	.76	.76	.93	.75	.65	.55	.50	.67	.55	.43	.42	.37	.31	.30

Rappresentiamo infine per immediatezza visiva le precedenti tabelle con istogrammi:

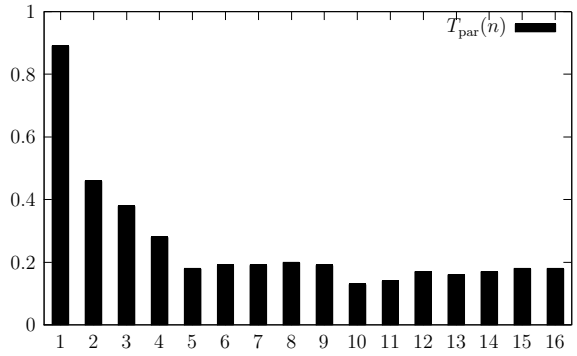

$T_{\text{par}}(n)$

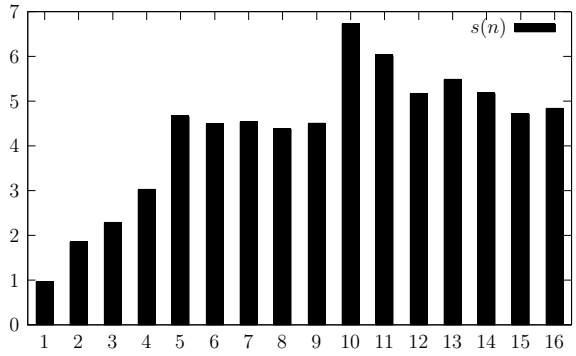

$s(n)$

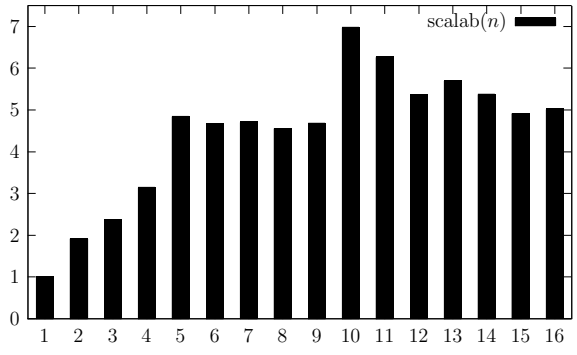

scalab(n)

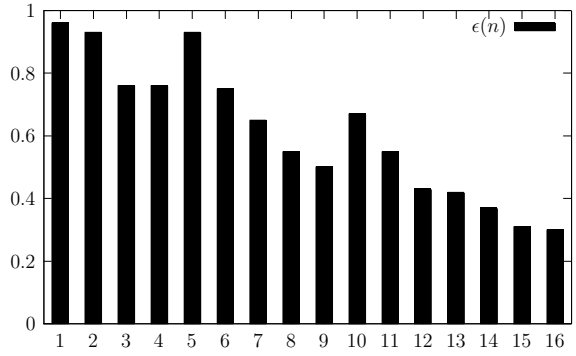

$\epsilon(n)$

Osserviamo che il programma scala, ma meno di quanto teoricamente atteso, in particolare su più di 10 processori.

5 Valutazione dei risultati

L'algoritmo implementato nel file `src/job.cpp` produce i seguenti risultati al variare della soglia `p`:

Originale

`p` = 20%

`p` = 40%

`p` = 60%

`p` = 80%

`p` = 99%

È inoltre possibile creare, usando l'utility `convert` di ImageMagick, una gif animata i cui frame siano le immagini risultanti al variare della soglia da 0 a 99. Per ottenerla è sufficiente invocare la rule `make gif` del `Makefile` oppure visitare il seguente indirizzo: http://raw.github.com/jacquerie/SPM/master/lena.gif.

A Manuale d'uso

A.1 Makefile

`all`: Invoca le rule `gif`, `parallel`, `sequential` e `tex`

`clean`: Rimuove i file generati dalle rule `gif`, `parallel`, `sequential` e `tex`.

`gif`: Genera una gif animata i cui frame sono le immagini risultanti al variare della soglia `p` da 0 a 99. Richiede l'installazione di ImageMagick e che `convert` sia nel `PATH`.

`parallel`: Compila con `sketocxx` l'implementazione parallela. Richiede l'installazione di SkeTo, una distribuzione di MPI compatibile e ImageMagick.

`sequential`: Compila con `g++` l'implementazione sequenziale. Richiede l'installazione di ImageMagick.

`tex`: Compila con `pdflatex` il presente documento. Richiede l'installazione di `pdflatex` e del pacchetto Python pygments.

A.2 Eseguibili

`./sequential numberOfJobs`: Esegue `sequential` su `numberOfJobs` istanze del problema dell'Histogram Thresholding. Stampa su `stdout` una coppia separata da uno spazio in cui il primo numero è `numberOfJobs` e il secondo il tempo in secondi impiegato da `sequential` a meno di operazioni di lettura e scrittura sul file system.

`./test_parallel [numberOfJobs=10]`: Aggiunge in coda al file `parallel.dat` i risultati di 10 invocazioni su `NP` processi, per `NP` che varia da 1 a 16, dell'implementazione parallela su istanze di taglia `numberOfJobs`. I risultati sono riportati come triple separate da spazi in cui il primo numero è `NP`, il secondo `numberOfJobs` e il terzo il tempo impiegato a meno di letture e scritture sul file system.

`./test_sequential [numberOfJobs=10]`: Invoca 10 volte `./sequential numberOfJobs` con valore di default 10, redirigendo `stdout` sul file `sequential.dat`.

Esiste infine la possibilità di invocare direttamente `./parallel` con la sintassi `sketorun -np NP ./parallel numberOfJobs`, in cui `NP` è il numero di processi che si desiderano far partire.

A.3 Licenza

Il codice è rilasciato con licenza MIT ed è disponibile su Github.